Prévia da Defesa de Mestrado

Estudo e Implementação de Códigos Corretores de Erros no Sistema de Arquivos Distribuído do Hadoop

Celina d' Ávila Samogin Instituto de Computação — UNICAMP

17 de dezembro de 2012

Orientadora: Profa. Dra. Islene Calciolari Garcia

- Introdução
- 2 Contexto em Sistemas Distribuídos e em Software Livre
- Métodos utilizados nesse Estudo e nessa Implementação
- Resultados
- 5 Referências Bibliográficas

Agenda

- Introdução
- 2 Contexto em Sistemas Distribuídos e em Software Livre
- Métodos utilizados nesse Estudo e nessa Implementação
- 4 Resultados
- Seferências Bibliográficas

- Este trabalho é uma contribuição para software livre em sistemas distribuídos.
- Armazenamento de dados ===> componente essencial na computação de alto desempenho.
- Códigos Corretores de Erro (*Erasure codes*) introduzem redundância para alcançar confiabilidade e redução do custo de armazenamento.

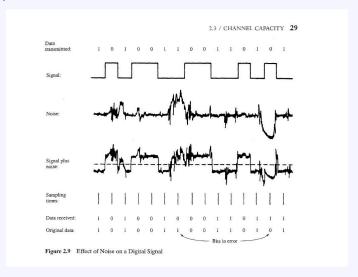


Figura: Efeito do ruído no sinal digital [22]

- Popularização dos computadores e as pesquisas espaciais ==> os códigos corretores de erros tornaram-se parte comum de comunicações por satélite, de redes de computadores, de armazenamento em discos óticos e outros meios magnéticos.
- Uso frequente em nosso cotidiano



Figura: Assistir programa de televisão Vila Sésamo[24]



Figura: Ouvir música a partir de um CD[3]



Figura: Atender um telefonema[9]




Figura: Navegar pela internet[7]

- Alguns sistemas que utilizam códigos corretores de erros:
 - NASA's Deep Space Network no envio e na recepção de sinais e dados de telemetria (downlinks) vindos de veículos espaciais (very distant spacecrafts) e para enviar telecomandos (uplinks) para veículos espaciais;
 - Delay and Disruption Tolerant Networks, redes de sensores e redes peer-to-peer;
 - armazenamento de grande volume de dados, como também o sistema de arquivos distribuído do Hadoop (HDFS).




Figura: NASA's Deep Space Network[15]



Figura: Facebook data center[25]

- O HDFS, por padrão, implementa alta disponibilidade dos dados via replicação simples dos blocos de dados. Esta abordagem acarreta um alto custo de armazenamento para garantir que os dados estarão sempre disponíveis.
- Esforços iniciais ===> Redundant Array of Independent Drives (RAID) [10, 16] e mais recentemente, Reed-Solomon (RS) [12].

- RAID (Redundant Arrays of Inexpensive [Independent] Disks (RAID), do ponto de vista de suas estruturas algébricas, é uma classe de códigos de blocos lineares.
- RAID é um método para prover tolerância a falhas ou alto desempenho em sistemas de armazenagem utilizando, para isso, distribuição de dados em diferentes dispositivos e uma codificação de correção de erros ou paridade ou replicação de dados [18].
- RAID foi introduzido por D. A. Patterson na Universidade da California, Berkeley (UC Berkeley) em 1988 [16].
- O código fonte do Hadoop implementa RAID-5, que na sua versão clássica, "fatia" dados e paridade, através dos discos, como num arranjo. A única paridade é calculada através da operação bitwise XOR.



Figura: RAID 5: 1 bloco de paridade e stripe = 4 blocos [13]

- Códigos Reed-Solomon (RS) são códigos de bloco, lineares e cíclicos (sobre anéis comutativos sob algumas condições).
- Parametrizáveis ===> capacidade de correção de erros pode ser alterada facilmente.
- RS são códigos MDS ===> as palavras-código apresentam máxima distância de Hamming entre si, permitida pelo número de dígitos de verificação de paridade do código.
- Segundo os autores em [2, 21], códigos RS são úteis para correção de erros em rajada.

Definition

Burst Errors Uma sequência de erros em rajada ou *burst errors* de tamanho b é da forma:

$$(0,0,\ldots,0,1,\ldots,1,0,\ldots,0,0)$$

onde o primeiro bit 1 está na i-posição e o último bit 1 está na (i+b-1)-posição e entre esses primeiro e último bits existe uma




Figura: RAID 6 clássico "fatia" dados e paridade, através dos discos, como num arranjo. A paridade P e Q são geradas pela operação *bitwise* XOR e pelo algoritmo Reed-Solomon.[14]

Objetivos deste trabalho

- avaliação de desempenho, ganhos, e custos de diferentes estratégias de códigos corretores de erro;
- implementação de otimizações ou extensões para o código fonte que atualmente implementa Reed-Solomon, tentando melhorar, principalmente, a parte de distribuição de blocos;
- implementação de novos algoritmos (Tornado e Turbo codes) e extensão da interface atual para aceitá-los;
- integração do código fonte atual com o HDFS.

Agenda

- Introdução
- Contexto em Sistemas Distribuídos e em Software Livre
- Métodos utilizados nesse Estudo e nessa Implementação
- 4 Resultados
- 5 Referências Bibliográficas

 Processar um volume relativamente grande de dados é possível, em poucas horas, com alguns dólares e com algumas máquinas: http://aws.amazon.com/

- Processar um volume relativamente grande de dados é possível, em poucas horas, com alguns dólares e com algumas máquinas: http://aws.amazon.com/
- Isto também pode ser feito com o Hadoop, um *framework* para processamento de dados em larga escala.

- Processar um volume relativamente grande de dados é possível, em poucas horas, com alguns dólares e com algumas máquinas: http://aws.amazon.com/
- Isto também pode ser feito com o Hadoop, um framework para processamento de dados em larga escala.
- Volume grande de dados ?

- Processar um volume relativamente grande de dados é possível, em poucas horas, com alguns dólares e com algumas máquinas: http://aws.amazon.com/
- Isto também pode ser feito com o Hadoop, um *framework* para processamento de dados em larga escala.
- Volume grande de dados ?
 - ▶ megabyte 10⁶ uma foto

- Processar um volume relativamente grande de dados é possível, em poucas horas, com alguns dólares e com algumas máquinas: http://aws.amazon.com/
- Isto também pode ser feito com o Hadoop, um framework para processamento de dados em larga escala.
- Volume grande de dados ?
 - ▶ megabyte 10⁶ uma foto
 - ▶ gigabyte 10⁹ um DVD armazena 4.7 GB de um filme

- Processar um volume relativamente grande de dados é possível, em poucas horas, com alguns dólares e com algumas máquinas: http://aws.amazon.com/
- Isto também pode ser feito com o Hadoop, um *framework* para processamento de dados em larga escala.
- Volume grande de dados ?
 - ▶ megabyte 10⁶ uma foto
 - gigabyte 10⁹ um DVD armazena 4.7 GB de um filme
 - ▶ terabyte 10¹² 200 filmes

- Processar um volume relativamente grande de dados é possível, em poucas horas, com alguns dólares e com algumas máquinas: http://aws.amazon.com/
- Isto também pode ser feito com o Hadoop, um *framework* para processamento de dados em larga escala.
- Volume grande de dados ?
 - ▶ megabyte 10⁶ uma foto
 - ▶ gigabyte 10⁹ um DVD armazena 4.7 GB de um filme
 - ▶ terabyte 10¹² 200 filmes
 - ▶ petabyte 10¹⁵

- Processar um volume relativamente grande de dados é possível, em poucas horas, com alguns dólares e com algumas máquinas: http://aws.amazon.com/
- Isto também pode ser feito com o Hadoop, um *framework* para processamento de dados em larga escala.
- Volume grande de dados ?
 - ▶ megabyte 10⁶ uma foto
 - ▶ gigabyte 10⁹ um DVD armazena 4.7 GB de um filme
 - ▶ terabyte 10¹² 200 filmes
 - ▶ petabyte 10¹⁵
 - exabyte 10¹⁸

- Processar um volume relativamente grande de dados é possível, em poucas horas, com alguns dólares e com algumas máquinas: http://aws.amazon.com/
- Isto também pode ser feito com o Hadoop, um *framework* para processamento de dados em larga escala.
- Volume grande de dados ?
 - ▶ megabyte 10⁶ uma foto
 - ▶ gigabyte 10⁹ um DVD armazena 4.7 GB de um filme
 - ► terabyte 10¹² 200 filmes
 - ▶ petabyte 10¹⁵
 - ► exabyte 10^{18}
 - ightharpoonup zettabyte 10^{21} um disco de 140 GB para cada pessoa no mundo

Software Open Source





















 O Hadoop disponibiliza um armazenamento compartilhado (HDFS/Hadoop *Distributed Filesystem*) e um sistema de análise (MapReduce), formando um framework ou arcabouço.

Por que não usamos banco de dados ?

 Em um banco de dados, uma atualização da árvore-B pode gerar muitas operações de seeking.

- Em um banco de dados, uma atualização da árvore-B pode gerar muitas operações de seeking.
- seek time processo de mover a cabeça do disco para um dado local no disco com o objetivo de ler ou de escrever dados

- Em um banco de dados, uma atualização da árvore-B pode gerar muitas operações de seeking.
- seek time processo de mover a cabeça do disco para um dado local no disco com o objetivo de ler ou de escrever dados
- É mais rápido usar um algoritmo de ordenação (sort/merge) para:

- Em um banco de dados, uma atualização da árvore-B pode gerar muitas operações de seeking.
- seek time processo de mover a cabeça do disco para um dado local no disco com o objetivo de ler ou de escrever dados
- É mais rápido usar um algoritmo de ordenação (sort/merge) para:
 - analisar um grande volume de dados do tamanho de petabytes

- Em um banco de dados, uma atualização da árvore-B pode gerar muitas operações de seeking.
- seek time processo de mover a cabeça do disco para um dado local no disco com o objetivo de ler ou de escrever dados
- É mais rápido usar um algoritmo de ordenação (sort/merge) para:
 - analisar um grande volume de dados do tamanho de petabytes
 - reconstruir toda a base de dados


	Aplicação para RDBMS	Aplicação para HDF- S/MapReduce
tamanho	gigabytes	petabytes
acesso	OLTP(interativo) e batch	batch
atualização	lê e escreve muitas vezes	escreve uma vez, lê muitas vezes
esquema	estático	dinâmico
integridade	alta	baixa
escala	não linear	linear

Fonte: [27]

HDFS



HFS disponibiliza espaço para sistema de arquivos e permite que os dados do usuário sejam armazenados em arquivos. Internamente, um arquivo é dividido em um ou mais blocos e esses blocos são armazenados em um conjunto de DataNodes. O tamanho *default* de cada bloco é 64MB.



Distributed Raid File

• 2 componentes

Distributed Raid File

2 componentes

▶ RaidNode: daemon cria os arquivos de paridade para os arquivos armazenados no hdfs e executa o scan nos arquivos com mais de 2 blocos e que não foram modificados nas últimas 24 horas; as exceções tratadas são: ChecksumException e BlocMissingException

Distributed Raid File

2 componentes

- ▶ RaidNode: daemon cria os arquivos de paridade para os arquivos armazenados no hdfs e executa o scan nos arquivos com mais de 2 blocos e que não foram modificados nas últimas 24 horas; as exceções tratadas são: ChecksumException e BlocMissingException
- raidfs: intercepta os pedidos de leitura vindos de uma aplicação ao hdfs client

Distributed Raid File

- 2 componentes
 - ▶ RaidNode: daemon cria os arquivos de paridade para os arquivos armazenados no hdfs e executa o scan nos arquivos com mais de 2 blocos e que não foram modificados nas últimas 24 horas; as exceções tratadas são: ChecksumException e BlocMissingException
 - raidfs: intercepta os pedidos de leitura vindos de uma aplicação ao hdfs client
- existe a ferramenta de linha de comando fsckraid



 Os dados que MapReduce processa são dados não estruturados como texto ou imagens. O HDFS, através do pipeline dos DataNodes, tenta colocar esses dados no nó onde são feitas as computações, desta forma, o acesso aos dados é rápido, pois é "mais" local.



- Os dados que MapReduce processa são dados não estruturados como texto ou imagens. O HDFS, através do pipeline dos DataNodes, tenta colocar esses dados no nó onde são feitas as computações, desta forma, o acesso aos dados é rápido, pois é "mais" local.
- O MapReduce pode resolver problemas genéricos cujos dados podem ser divididos em matrizes de dados, para cada matriz a mesma computação é necessária e não existe necessidade de comunicação entre as tarefas.



- Os dados que MapReduce processa são dados não estruturados como texto ou imagens. O HDFS, através do pipeline dos DataNodes, tenta colocar esses dados no nó onde são feitas as computações, desta forma, o acesso aos dados é rápido, pois é "mais" local.
- O MapReduce pode resolver problemas genéricos cujos dados podem ser divididos em matrizes de dados, para cada matriz a mesma computação é necessária e não existe necessidade de comunicação entre as tarefas.
- Problemas como empacotamento, linha de fábrica, otimização não são resolvidos pelo modelo de computação do MapReduce.



Problema genérico:

- iteração sobre um número grande de registros
- Map extrai algo de cada registro (chave, valor)
- rearranjo (shuffle e ordenação de resultados intermediários por (chave, valor)
- Reduce agrega os resultados intermediários
- geração da saída

Agenda

- Introdução
- Contexto em Sistemas Distribuídos e em Software Livre
- 3 Métodos utilizados nesse Estudo e nessa Implementação
- 4 Resultados
- 5 Referências Bibliográficas

• Erasure Coding

- Erasure Coding
- Exame de Qualificação para o Mestrado (EQM)

- Erasure Coding
- Exame de Qualificação para o Mestrado (EQM)
- Foco: armazenamento de dados

- Erasure Coding
- Exame de Qualificação para o Mestrado (EQM)
- Foco: armazenamento de dados
- Códigos corretores de erro disponíveis na versão 0.22 do Hadoop:
 RAID e RS



- Erasure Coding
- Exame de Qualificação para o Mestrado (EQM)
- Foco: armazenamento de dados
- Códigos corretores de erro disponíveis na versão 0.22 do Hadoop: RAID e RS



 Muitos artigos e material de aulas das disciplinas de universidades de Portugal, Índia, Paquistão e EUA

Congruência linear

- Congruência linear
- Classes Residuais

- Congruência linear
- Classes Residuais
- Resto da divisão euclidiana

- Congruência linear
- Classes Residuais
- Resto da divisão euclidiana
- Independência linear

- Congruência linear
- Classes Residuais
- Resto da divisão euclidiana
- Independência linear
- \bullet Espaço Vetorial, Grupo, Anel e Corpo (principalmente \mathbb{GF}_2 e $\mathbb{GF}_{256})$

- Congruência linear
- Classes Residuais
- Resto da divisão euclidiana
- Independência linear
- \bullet Espaço Vetorial, Grupo, Anel e Corpo (principalmente \mathbb{GF}_2 e $\mathbb{GF}_{256})$
- Sistema de Equações Lineares

- Congruência linear
- Classes Residuais
- Resto da divisão euclidiana
- Independência linear
- \bullet Espaço Vetorial, Grupo, Anel e Corpo (principalmente \mathbb{GF}_2 e $\mathbb{GF}_{256})$
- Sistema de Equações Lineares
- Matrizes

- Congruência linear
- Classes Residuais
- Resto da divisão euclidiana
- Independência linear
- \bullet Espaço Vetorial, Grupo, Anel e Corpo (principalmente \mathbb{GF}_2 e $\mathbb{GF}_{256})$
- Sistema de Equações Lineares
- Matrizes
- Polinômios

Definition

Congruência Linear Seja $q \in \mathbb{Z}$. Dois inteiros $a \in b$ dizem-se congruentes módulo q se, e somente se, q divide a - b. A notação é $a \equiv b \pmod{q}$. Assim, $a - b \in \{x \ tal \ que \ x = kq, k \in \mathbb{Z}\}$.

Example

$$32 \equiv 2 \pmod{3}$$

$$27 \equiv 5 \pmod{11}$$

$$63 \equiv 7 \pmod{8}$$

Definition

Conjunto das Classes Residuais Seja $\mathbb{Z}/q=\{\bar{0}_q,\bar{1}_q,\ldots,\overline{q-1}_q\}$ o conjunto das classes residuais dos inteiros módulo q.

Note que \mathbb{Z}/q tem exatamente q elementos, portanto \mathbb{Z}/q é finito. As classes residuais possuem propriedades:

- (i) Se a $\equiv b \pmod{q}$, então $ar{a}_q = ar{b}_q$.
- (ii) Se $\bar{a}_q\cap \bar{b}_q
 eq 0$, então $\bar{a}_q=\bar{b}_q$.
- (iii) Para $a \in \mathbb{Z}, \bigcup \bar{a}_q = \mathbb{Z}$.

 Teoria da codificação ===> propriedades dos códigos e suas aplicações


- Teoria da codificação ===> propriedades dos códigos e suas aplicações
- Teoria da Informação, Claude Shannon [20] ===> incerteza da informação e capacidade do canal

- Teoria da codificação ===> propriedades dos códigos e suas aplicações
- Teoria da Informação, Claude Shannon [20] ===> incerteza da informação e capacidade do canal
- C. Shannon estudou o processamento digital de sinais (sinais em tempo discreto e em tempo contínuo) em um sistema de comunicação ===> hoje, é área da engenharia elétrica e da matemática aplicada

- Teoria da codificação ===> propriedades dos códigos e suas aplicações
- Teoria da Informação, Claude Shannon [20] ===> incerteza da informação e capacidade do canal
- C. Shannon estudou o processamento digital de sinais (sinais em tempo discreto e em tempo contínuo) em um sistema de comunicação ===> hoje, é área da engenharia elétrica e da matemática aplicada
- Sinais podem ser som, áudio, dados biológicos como eletrocardiogramas ou sequências de DNA [6, 8], sinais de sistemas de telecomunicações, entre muitos outros.

- Teoria da codificação ===> propriedades dos códigos e suas aplicações
- Teoria da Informação, Claude Shannon [20] ===> incerteza da informação e capacidade do canal
- C. Shannon estudou o processamento digital de sinais (sinais em tempo discreto e em tempo contínuo) em um sistema de comunicação ===> hoje, é área da engenharia elétrica e da matemática aplicada
- Sinais podem ser som, áudio, dados biológicos como eletrocardiogramas ou sequências de DNA [6, 8], sinais de sistemas de telecomunicações, entre muitos outros.
- Objetivo da codificação de canal é aumentar a resistência do sistema de comunicações digital face aos efeitos do ruído de canal.

Canal binário simétrico



 A ciclicidade de códigos sob anéis comutativos está associada à multiplicação do polinômio gerador pelos diferentes potências de "x" reduzida módulo um polinômio irredutível.

Detectar erros e codificar dados tem a mesma complexidade

- Detectar erros e codificar dados tem a mesma complexidade
- Decodificar é np-completo

- Detectar erros e codificar dados tem a mesma complexidade
- Decodificar é np-completo
- Estruturas algébricas: matrizes

Conhecer e Compilar o código fonte disponível



• Facebook, Yahoo, Fundação Apache

Conhecer e Compilar o código fonte disponível



- Facebook, Yahoo, Fundação Apache
- O kernel do Hadoop é constituído do core, hdfs e mapred.

Conhecer e Compilar o código fonte disponível



- Facebook, Yahoo, Fundação Apache
- O kernel do Hadoop é constituído do core, hdfs e mapred.
- As versões oficiais para instalação (http://www.apache.org/dist/hadoop/core/) e



- Facebook, Yahoo, Fundação Apache
- O kernel do Hadoop é constituído do core, hdfs e mapred.
- As versões oficiais para instalação (http://www.apache.org/dist/hadoop/core/) e
- as versões do código fonte (common, hdfs, mapreduce) estão disponíveis em repositório SVN (https://svn.apache.org/repos/asf/hadoop/common/branches/branch-0.22)



- Facebook, Yahoo, Fundação Apache
- O kernel do Hadoop é constituído do core, hdfs e mapred.
- As versões oficiais para instalação (http://www.apache.org/dist/hadoop/core/) e
- as versões do código fonte (common, hdfs, mapreduce) estão disponíveis em repositório SVN (https://svn.apache.org/repos/asf/hadoop/common/branches/branch-0.22)
- Na atividade Scripts for building Hadoop 0.22.0 release https://issues.apache.org/jira/browse/HADOOP-6846, os mantenedores e contribuidores do Hadoop discutiam como compilar a versão 0.22

• Eclipse IDE for Java

- Eclipse IDE for Java
- comandos do linux, principalmente, grep, find e editores de texto

- Eclipse IDE for Java
- comandos do linux, principalmente, grep, find e editores de texto
- Doxygen para gerar diagramas de herança e de colaboração das classes a partir do código fonte

- Eclipse IDE for Java
- comandos do linux, principalmente, grep, find e editores de texto
- Doxygen para gerar diagramas de herança e de colaboração das classes a partir do código fonte
- Implementar uma aplicação do framework do Hadoop: conta-palavras, temperatura máxima, page rank

- Eclipse IDE for Java
- comandos do linux, principalmente, grep, find e editores de texto
- Doxygen para gerar diagramas de herança e de colaboração das classes a partir do código fonte
- Implementar uma aplicação do framework do Hadoop: conta-palavras, temperatura máxima, page rank
- Fazer uma pequena alteração no código fonte do RaidNode () para escrever uma mensagem no arquivo de log, compilar o código fonte modificado, instalá-lo e testá-lo

 Hadoop foi escrito quase que inteiramente em Java: construtores de classe, asserções

- Hadoop foi escrito quase que inteiramente em Java: construtores de classe, asserções
- Java: 1o capítulo do livro vermelho do Sedgewick, Algorithms

- Hadoop foi escrito quase que inteiramente em Java: construtores de classe, asserções
- Java: 1o capítulo do livro vermelho do Sedgewick, Algorithms
- Entender a camada RAID para poder extendê-la

- Hadoop foi escrito quase que inteiramente em Java: construtores de classe, asserções
- Java: 1o capítulo do livro vermelho do Sedgewick, Algorithms
- Entender a camada RAID para poder extendê-la
- Entender de álgebra abstrata e de uma de suas aplicações: códigos corretores de erros

- Hadoop foi escrito quase que inteiramente em Java: construtores de classe, asserções
- Java: 1o capítulo do livro vermelho do Sedgewick, Algorithms
- Entender a camada RAID para poder extendê-la
- Entender de álgebra abstrata e de uma de suas aplicações: códigos corretores de erros
- Propor os algoritmos dos novos codecs: encode e decode

• Ambiente de edição do código fonte das classes

- Ambiente de edição do código fonte das classes
 - ▶ Notebook com Ubuntu 8.04, depois 10.04, depois 12.04 (2*GB* de RAM, *dual-core*, 150*MB* de disco interno, 1.35*TB* de disco externo)

- Ambiente de edição do código fonte das classes
 - ▶ Notebook com Ubuntu 8.04, depois 10.04, depois 12.04 (2*GB* de RAM, *dual-core*, 150*MB* de disco interno, 1.35*TB* de disco externo)
- Ambiente de compilação do Hadoop versão 0.22

- Ambiente de edição do código fonte das classes
 - ▶ Notebook com Ubuntu 8.04, depois 10.04, depois 12.04 (2*GB* de RAM, *dual-core*, 150*MB* de disco interno, 1.35*TB* de disco externo)
- Ambiente de compilação do Hadoop versão 0.22
 - Notebook com Ubuntu

- Ambiente de edição do código fonte das classes
 - ▶ Notebook com Ubuntu 8.04, depois 10.04, depois 12.04 (2*GB* de RAM, *dual-core*, 150*MB* de disco interno, 1.35*TB* de disco externo)
- Ambiente de compilação do Hadoop versão 0.22
 - Notebook com Ubuntu
 - Laboratório da pós-graduação do IC; estação 64 bits com Fedora

- Ambiente de edição do código fonte das classes
 - ▶ Notebook com Ubuntu 8.04, depois 10.04, depois 12.04 (2*GB* de RAM, *dual-core*, 150*MB* de disco interno, 1.35*TB* de disco externo)
- Ambiente de compilação do Hadoop versão 0.22
 - Notebook com Ubuntu
 - Laboratório da pós-graduação do IC; estação 64 bits com Fedora
 - ▶ Instâncias da Amazon EC2 (servidoras virtuais na Nuvem) com Ubuntu 12.10, kernel, (613MB de RAM, dual-core, alguns gigabytes de disco)

- Ambiente de edição do código fonte das classes
 - ▶ Notebook com Ubuntu 8.04, depois 10.04, depois 12.04 (2*GB* de RAM, *dual-core*, 150*MB* de disco interno, 1.35*TB* de disco externo)
- Ambiente de compilação do Hadoop versão 0.22
 - Notebook com Ubuntu
 - Laboratório da pós-graduação do IC; estação 64 bits com Fedora
 - ▶ Instâncias da Amazon EC2 (servidoras virtuais na Nuvem) com Ubuntu 12.10, kernel, (613MB de RAM, dual-core, alguns gigabytes de disco)
- Ambiente de instalação do tarball

- Ambiente de edição do código fonte das classes
 - ▶ Notebook com Ubuntu 8.04, depois 10.04, depois 12.04 (2*GB* de RAM, *dual-core*, 150*MB* de disco interno, 1.35*TB* de disco externo)
- Ambiente de compilação do Hadoop versão 0.22
 - Notebook com Ubuntu
 - Laboratório da pós-graduação do IC; estação 64 bits com Fedora
 - ▶ Instâncias da Amazon EC2 (servidoras virtuais na Nuvem) com Ubuntu 12.10, kernel, (613MB de RAM, dual-core, alguns gigabytes de disco)
- Ambiente de instalação do tarball
 - Notebook com Ubuntu

- Ambiente de edição do código fonte das classes
 - ▶ Notebook com Ubuntu 8.04, depois 10.04, depois 12.04 (2*GB* de RAM, *dual-core*, 150*MB* de disco interno, 1.35*TB* de disco externo)
- Ambiente de compilação do Hadoop versão 0.22
 - Notebook com Ubuntu
 - Laboratório da pós-graduação do IC; estação 64 bits com Fedora
 - ▶ Instâncias da Amazon EC2 (servidoras virtuais na Nuvem) com Ubuntu 12.10, kernel, (613MB de RAM, dual-core, alguns gigabytes de disco)
- Ambiente de instalação do tarball
 - Notebook com Ubuntu
 - ► Instâncias da Amazon EC2

Testes Iniciais

Notebook com Ubuntu

Testes Iniciais

- Notebook com Ubuntu
- Testes funcionais: encode e decode das novas codificações e correção de erros no código fonte das classes das codificações implementadas por esse trabalho ===> linguagem Java.

• Instâncias da Amazon EC2 (servidoras virtuais na Nuvem) com Ubuntu 12.10, *kernel*, (613*MB* de RAM, *dual-core*, alguns *gigabytes* de disco)

- Instâncias da Amazon EC2 (servidoras virtuais na Nuvem) com Ubuntu 12.10, kernel, (613MB de RAM, dual-core, alguns gigabytes de disco)
- AWS Console e Amazon EC2 API tools (ferramentas de linha de comando)

- Instâncias da Amazon EC2 (servidoras virtuais na Nuvem) com Ubuntu 12.10, kernel, (613MB de RAM, dual-core, alguns gigabytes de disco)
- AWS Console e Amazon EC2 API tools (ferramentas de linha de comando)
- 3 fases de Testes de Desempenho (coleta de dados) da operação de encode e de Injeção de Falhas das operações de encode e decode das novas codificações

- Instâncias da Amazon EC2 (servidoras virtuais na Nuvem) com Ubuntu 12.10, kernel, (613MB de RAM, dual-core, alguns gigabytes de disco)
- AWS Console e Amazon EC2 API tools (ferramentas de linha de comando)
- 3 fases de Testes de Desempenho (coleta de dados) da operação de encode e de Injeção de Falhas das operações de encode e decode das novas codificações
- Primeira fase: preparação do ambiente de teste

- Instâncias da Amazon EC2 (servidoras virtuais na Nuvem) com Ubuntu 12.10, kernel, (613MB de RAM, dual-core, alguns gigabytes de disco)
- AWS Console e Amazon EC2 API tools (ferramentas de linha de comando)
- 3 fases de Testes de Desempenho (coleta de dados) da operação de encode e de Injeção de Falhas das operações de encode e decode das novas codificações
- Primeira fase: preparação do ambiente de teste
- Rede de 4 instâncias: 1 master/slave e 3 slaves

- Instâncias da Amazon EC2 (servidoras virtuais na Nuvem) com Ubuntu 12.10, kernel, (613MB de RAM, dual-core, alguns gigabytes de disco)
- AWS Console e Amazon EC2 API tools (ferramentas de linha de comando)
- 3 fases de Testes de Desempenho (coleta de dados) da operação de encode e de Injeção de Falhas das operações de encode e decode das novas codificações
- Primeira fase: preparação do ambiente de teste
- Rede de 4 instâncias: 1 master/slave e 3 slaves
- Base de dados: imagens ISO (+-800MB cada uma)

- Segunda fase: coleta de dados para medição de desempenho da operações de encode e de decode para cada codificação:
 - replicação simples 2X
 - ► replicação simples 3X
 - ► *XOR*(6,5)
 - ► *RS*(8,5)
 - ▶ Tornado(10, 5)
 - ► Tornado(20, 10)
 - ► *Turbo* − *like*(10, 5)
 - ► Turbo like(20, 10)

- Segunda fase: coleta de dados para medição de desempenho da operações de encode e de decode para cada codificação:
 - replicação simples 2X
 - ▶ replicação simples 3X
 - ► XOR(6,5)
 - ► RS(8,5)
 - ► Tornado(10, 5)
 - ► Tornado(20, 10)
 - ► *Turbo like*(10, 5)
 - ► Turbo like(20, 10)
- Rede de 16 instâncias large, provavelmente
- Base de dados: imagens ISO

- Terceira fase: coleta de dados para medição da injeção de falhas falha em 1 réplica : corromper 1 réplica de blocos de dados de um arquivo
 - falha em *n* réplicas corromper *n* réplicas de blocos de dados de um arquivo
 - falha em réplicas e em blocos de dados corromper n réplicas de blocos de dados e os k-1 blocos de dados de um arquivo

- Terceira fase: coleta de dados para medição da injeção de falhas falha em 1 réplica : corromper 1 réplica de blocos de dados de um arquivo
 - falha em n réplicas corromper n réplicas de blocos de dados de um arquivo
 - falha em réplicas e em blocos de dados corromper n réplicas de blocos de dados e os k-1 blocos de dados de um arquivo
- Rede de 16 instâncias large, provavelmente

- Terceira fase: coleta de dados para medição da injeção de falhas falha em 1 réplica : corromper 1 réplica de blocos de dados de um arquivo
 - falha em n réplicas corromper n réplicas de blocos de dados de um arquivo
 - falha em réplicas e em blocos de dados corromper n réplicas de blocos de dados e os k-1 blocos de dados de um arquivo
- Rede de 16 instâncias large, provavelmente
- Base de dados: imagens ISO

Métricas por Codificação	Origem
Tempo total de execução do experimento	sistema operacional
Tamanho do arquivo carregado no hdfs	interface web do hdfs
Tempo de carga no hdfs por arquivo	arquivo de log do RaidNode
Tempo de execução/encode por arquivo codificado	arquivo de log do RaidNode
Tempo de execução/decode por arquivo decodificado	arquivo de log do RaidNode
Número de iterações na execução do decode	arquivo de log do RaidNode
Tamanho do bloco do hdfs	arquivo de configuração do hdfs
Número de blocos da <i>stripe</i>	arquivo de configuração do hdfs
Fator de redundância previsto por arquivo	texto desta dissertação
Fator de redundância por arquivo obtido nos experimentos	interface web do hdfs
Número de blocos com falhas suportado	arquivo de configuração do hdfs
Número de blocos com falhas obtido nos experimentos	arquivo de log do RaidNode

Tabela: Métricas quantitativas coletadas por codificação nos experimentos para operações de *encode* e de *decode*

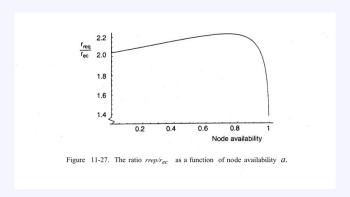


Figura: Razão sobrecarga da replicação/sobrecarga da codificação X disponibilidade dos nós [23]

Agenda

- Introdução
- Contexto em Sistemas Distribuídos e em Software Livre
- Métodos utilizados nesse Estudo e nessa Implementação
- 4 Resultados
- 5 Referências Bibliográficas

• Esse trabalho estendeu e alterou código fonte distribuído sob a licença Apache.

- Esse trabalho estendeu e alterou código fonte distribuído sob a licença Apache.
- Com as codificações RAID, RS, já disponíveis no HDFS e as codificações Tornado e Turbo-like, implementadas por esse trabalho de mestrado, o HDFS disponibiliza, com uma flexível configuração, as principais codificações para canal binário simétrico

- Esse trabalho estendeu e alterou código fonte distribuído sob a licença Apache.
- Com as codificações RAID, RS, já disponíveis no HDFS e as codificações Tornado e Turbo-like, implementadas por esse trabalho de mestrado, o HDFS disponibiliza, com uma flexível configuração, as principais codificações para canal binário simétrico
- Os diagramas de herança e de colaboração para as classes e o código fonte dos procedimentos de compilação e de geração do arquivo tarball foram disponibilizados em repositório público ¹.

- Esse trabalho estendeu e alterou código fonte distribuído sob a licença Apache.
- Com as codificações RAID, RS, já disponíveis no HDFS e as codificações Tornado e Turbo-like, implementadas por esse trabalho de mestrado, o HDFS disponibiliza, com uma flexível configuração, as principais codificações para canal binário simétrico
- Os diagramas de herança e de colaboração para as classes e o código fonte dos procedimentos de compilação e de geração do arquivo tarball foram disponibilizados em repositório público ¹.
- O código fonte da implementação das codificações será disponibilizado em breve

 Foram criados um site ² com comentários dos resultados obtidos desse trabalho e um *blog* ³ para comentar assuntos que a autora considerou de grande interesse para outras pessoas.

Celina d' Á. Samogin ()



 $^{^2} https://sites.google.com/site/newerasurecodinginhadoop\\$

³http://mcss.posterous.com/

- Foram criados um site ² com comentários dos resultados obtidos desse trabalho e um *blog* ³ para comentar assuntos que a autora considerou de grande interesse para outras pessoas.
- Um dos cenários de uso de codificações baseadas em grafos seria em ambientes de data center, onde um grande número de máquinas poderiam falhar. Com blocos de paridade íntegros dos arquivos com, pelo menos, 1 dos blocos de dados dos mesmos arquivos disponível, há uma grande probabilidade desse tipo de codificação recuperar os blocos de dados corrompidos. Essa é uma aplicação das codificações implementadas por esse trabalho.



²https://sites.google.com/site/newerasurecodinginhadoop

³http://mcss.posterous.com/

 Esse trabalho discutiu esquemas adequados de redundância de dados apenas sobre o aspecto do esquema de dados, sem comentar algoritmos de atualização das réplicas.

- Esse trabalho discutiu esquemas adequados de redundância de dados apenas sobre o aspecto do esquema de dados, sem comentar algoritmos de atualização das réplicas.
- Pode-se concluir com uma aplicação do teorema da Codificação do Canal [1, 19], que um sistema com largura de banda a maior possível tem uma capacidade de canal finita. Em esboços preliminares, comparando-se, para uma dada codificação, pode-se concluir que a probabilidade de erro em uma palavra código sem codificação é maior que a probabilidade de erro em uma palavra código com codificação.

- Esse trabalho discutiu esquemas adequados de redundância de dados apenas sobre o aspecto do esquema de dados, sem comentar algoritmos de atualização das réplicas.
- Pode-se concluir com uma aplicação do teorema da Codificação do Canal [1, 19], que um sistema com largura de banda a maior possível tem uma capacidade de canal finita. Em esboços preliminares, comparando-se, para uma dada codificação, pode-se concluir que a probabilidade de erro em uma palavra código sem codificação é maior que a probabilidade de erro em uma palavra código com codificação.
- O estudo da independência das réplicas de um esquema de redundância é um campo promissor para pesquisas. A avaliação de esquemas de redundância é muitas vezes baseada na suposição de que as réplicas falham de forma independente. Na prática, as falhas não são tão independentes, segundo [4, 26].

 Uma extensão do algoritmo da camada RAID pode melhorar o desempenho da tolerância à falhas.

- Uma extensão do algoritmo da camada RAID pode melhorar o desempenho da tolerância à falhas.
- Aplicações de códigos corretores de erros em outros canais binários simétricos e suas extensões como joint source-channel coding parecem uma pesquisa promissora, pois "contenar" codificação de fonte e de canal, tem sido proposto para implementar aplicações que tem requisitos de tempo-real como transmissão de áudio e imagem em um canal binário simétrico com ruído [17].

- Uma extensão do algoritmo da camada RAID pode melhorar o desempenho da tolerância à falhas.
- Aplicações de códigos corretores de erros em outros canais binários simétricos e suas extensões como joint source—channel coding parecem uma pesquisa promissora, pois "contenar" codificação de fonte e de canal, tem sido proposto para implementar aplicações que tem requisitos de tempo-real como transmissão de áudio e imagem em um canal binário simétrico com ruído [17].
- O estudo e a implementação de outros mecanismos e técnicas para redução de armazenamento e disponibilidade de dados, otimizando o desempenho de codificações baseadas em grafos, como códigos LDPC

- Uma extensão do algoritmo da camada RAID pode melhorar o desempenho da tolerância à falhas.
- Aplicações de códigos corretores de erros em outros canais binários simétricos e suas extensões como joint source-channel coding parecem uma pesquisa promissora, pois "contenar" codificação de fonte e de canal, tem sido proposto para implementar aplicações que tem requisitos de tempo-real como transmissão de áudio e imagem em um canal binário simétrico com ruído [17].
- O estudo e a implementação de outros mecanismos e técnicas para redução de armazenamento e disponibilidade de dados, otimizando o desempenho de codificações baseadas em grafos, como códigos LDPC
- O estudo e implementação de aplicações de códigos corretores de erros, tanto a com memória como a sem memória, para os canais do DNA e do RNA [5, 8] é uma pesquisa bastante desafiadora e promissora.

 As versões do hadoop relacionadas a esta proposta: 0.20.1, 0.21.0 e 0.22.0 do Hadoop

- As versões do hadoop relacionadas a esta proposta: 0.20.1, 0.21.0 e 0.22.0 do Hadoop
- Analisadas um pouco mais de 120 discussões do jira

- As versões do hadoop relacionadas a esta proposta: 0.20.1, 0.21.0 e 0.22.0 do Hadoop
- Analisadas um pouco mais de 120 discussões do jira
- Buscas no jira issues.apache.org/, selecionando projeto "Hadoop Map/Reduce" e componente "contrib/raid", mostram algumas discussões sobre as camadas de codificação por apagamento

- As versões do hadoop relacionadas a esta proposta: 0.20.1, 0.21.0 e 0.22.0 do Hadoop
- Analisadas um pouco mais de 120 discussões do jira
- Buscas no jira issues.apache.org/, selecionando projeto "Hadoop Map/Reduce" e componente "contrib/raid", mostram algumas discussões sobre as camadas de codificação por apagamento
- Camada RAID: versão 0.21.0 (discussão HDFS-503)

- As versões do hadoop relacionadas a esta proposta: 0.20.1, 0.21.0 e 0.22.0 do Hadoop
- Analisadas um pouco mais de 120 discussões do jira
- Buscas no jira issues.apache.org/, selecionando projeto "Hadoop Map/Reduce" e componente "contrib/raid", mostram algumas discussões sobre as camadas de codificação por apagamento
- Camada RAID: versão 0.21.0 (discussão HDFS-503)
- Codificação RS: versão 0.22.0 (discussões MAPREDUCE-1969 e MAPREDUCE-1970)

- As versões do hadoop relacionadas a esta proposta: 0.20.1, 0.21.0 e 0.22.0 do Hadoop
- Analisadas um pouco mais de 120 discussões do jira
- Buscas no jira issues.apache.org/, selecionando projeto "Hadoop Map/Reduce" e componente "contrib/raid", mostram algumas discussões sobre as camadas de codificação por apagamento
- Camada RAID: versão 0.21.0 (discussão HDFS-503)
- Codificação RS: versão 0.22.0 (discussões MAPREDUCE-1969 e MAPREDUCE-1970)
- Codificação Tornado e Turbo-like: possivelmente em versões futuras

- Existe um grupo de contribuidores (de várias empresas como Cloudera, Facebook, Yahoo e de universidades como *University of* Waterloo e Carnegie Mellow *University*) da camada RAID, dos quais, destacamos Rodrigo Schmidt, ex-aluno do programa de pós-graduação do Instituto de Computação da Unicamp, que sugeriu o tema deste trabalho e que tem contribuído com várias idéias para a realização deste trabalho.
- Foi possível uma saudável interação e colaboração com os desenvolvedores.

Agradecimentos

- CNPq (Conselho Nacional de Desenvolvimento Científico e Tecnológico)
- FAPESP (Fundação de Amparo à Pesquisa do Estado de São Paulo)
- IC (Instituto de Computação da Unicamp)
- Embrapa (Empresa Brasileira de Pesquisa Agropecuária)

Agenda

- Introdução
- Contexto em Sistemas Distribuídos e em Software Livre
- Métodos utilizados nesse Estudo e nessa Implementação
- 4 Resultados
- 5 Referências Bibliográficas

Referências Bibliográficas I



Códigos Corretores de Erros em Comunicações Digitais, chapter 1,2,3,4,5,6,7,8,9, pages 17–600.

FEUP edições, Porto, Portugal, 2001.



🚺 G. M. Almeida.

Códigos corretores de erros em hardware para sistemas de telecomando e telemetria em aplicações espaciais.

Master's thesis, Pontifícia Universidade Católica do Rio Grande do Sul - Faculdade de Informática, Porto Alegre, Brasil, março 2007.



Mari angela.

Notas da alma.

URL=http://vidaanascer.blogspot.com.br/2012/09/notas-da-alma.html. Acessado em 10 de dezembro de 2012.

Referências Bibliográficas II



M. Baker, M. Shah, D. S. H. Rosenthal, M. Roussopoulos, P. Maniatis, TJ. Giuli, and P. Bungale.

A fresh look at the reliability of long-term digital storage. In *Proceedings of the 1st ACM SIGOPS/EuroSys European Conference on Computer Systems*, EuroSys '06, pages 221–234, New York, NY, USA, 2006. ACM.



Andréa Santos Leite da Rocha.

Modelo de Sistema de Comunicações Digital para o Mecanismo de Importação de Proteínas Mitocondriais Através de Códigos Corretores de Erros.

doctoral dissertation, Departamento de Telemática, Faculdade de Engenharia Elétrica e de Computação, Universidade Estadual de Campinas, Campinas, Brasil, 2010.

Referências Bibliográficas III

Luzinete Cristina Bonani de Faria.

Existencias de Códigos Corretores de Erros e Protocolos de Comunicação em Sequências de DNA.

doctoral dissertation, Departamento de Telemática, Faculdade de Engenharia Elétrica e de Computação, Universidade Estadual de Campinas, Campinas, Brasil, 2011.

Fábio Berbert de Paula.

Criando sites para celular com wml (parte 1).

URL=http://phpbrasil.com/artigo/ozk4Kml6_tdC/2/criando-sites-para-celular-com-wml-parte-1. Acessado em 10 de dezembro de 2012.

Referências Bibliográficas IV

Luzinete C. B. Faria, Andréa S. L. Rocha, João H. Kleinschmidt, Márcio C. Silva-Filho, Edson Bim, Roberto H. Herai, Michel E. B. Yamagishi, and Reginaldo Palazzo Jr.

Is a genome a codeword of an error-correcting code? *PLoS ONE*, 7(5):e36644, 05 2012.

Volney Faustini.

O telefone tocou na madrugada.

URL=http://volneyf.blogspot.com.br/2008_04_01_archive.html. Acessado em 10 de dezembro de 2012.

Apache Software Foundation.

Hdfs-503 - implement erasure coding as a layer on hdfs.

URL=https://issues.apache.org/jira/browse/HDFS-503. Acessado em 08 de maio de 2010.

Referências Bibliográficas V



Apache Software Foundation.

Hdfs architecture.

URL=http://hadoop.apache.org/common/docs/current/hdfs_design.htm Acessado em 08 de maio de 2010.



Apache Software Foundation.

Mapreduce-1969 - allow raid to use reed-solomon erasure codes.

URL=https://issues.apache.org/jira/browse/MAPREDUCE-1969.

Acessado em 20 de agosto de 2010.



Apache Software Foundation.

Mapreduce-2036 - enable erasure code in tool similar to hadoop archive.

URL=https://issues.apache.org/jira/browse/MAPREDUCE-2036. Acessado em 10 de novembro de 2010.

Referências Bibliográficas VI



Raid 6.

URL=http://pic.dhe.ibm.com/infocenter/powersys/v3r1m5/index.jsp?topAcessado em 10 de dezembro de 2012.

California Institute of Technology Jet Propulsion Laboratory.

Telecommunications.

URL=http://www2.jpl.nasa.gov/basics/bsf10-1.php. Acessado em 10 de dezembro de 2012.

🔋 D. A. Patterson, G. Gibson, and R. H. Katz.

A case for redundant arrays of inexpensive disks (raid).

In SIGMOD '88: Proceedings of the 1988 ACM SIGMOD International Conference on Management of Data, pages 109–116, New York, NY, USA, 1988. ACM.

Referências Bibliográficas VII

Wikipedia project.

Joint source and channel coding.

URL=http://en.wikipedia.org/wiki/Joint_source_and_channel_coding. Acessado em 7 de junho de 2012.

Raghu Ramakrishnan and Johannes Gehrke.

Database Management Systems, chapter 9, pages 304–337.

McGraw-Hill, New York, NY, USA, 2003.

Mischa Schwartz.

Information transmission, modulation and noise, chapter 3, 7, pages 95–200, 564–730.

McGraw-Hill, Singapure, 1990.

C. E. Shannon.

A mathematical theory of communication.

The Bell System Technical Journal, 27(3):379-423, 623-656, 1948.

Referências Bibliográficas VIII



The Theory of Error-Correcting Codes, chapter 3, 4, 7, 10, pages 80–124.

North-Holland Publishing Company, Amsterdam, Netherlands, 1977.

William Stallings.

Wireless Communications and Networks, chapter 2, 8, pages 14–45, 193–235.

Prentice Hall, Upper Saddle River, NJ, USA, 2005.

Andrew S. Tanenbaum and Maarten Van Steen.

Distributed systems: principles and paradigms, chapter 8,11, pages 321–375,491–544.

Prentice Hall, Upper Saddle River, New Jersey, USA, 2006.

Referências Bibliográficas IX



Programas infantis que fizeram história.

URL=http://worldtelevisao.blogspot.com.br/2011/05/programas-infantis-que-fizeram-historia.html. Acessado em 10 de dezembro de 2012.



How facebook kept its servers cool in the southern summer heat. URL=http://venturebeat.com/2012/11/14/facebook-north-carolina-data-center/. Acessado em 10 de dezembro de 2012.

H. Weatherspoon, T. Moscovitz, and J. Kubiatowicz. Introspective failure analysis: Avoiding correlated failures in peer-to-peer systems.

21st IEEE Symposium on Reliable Distributed Systems, 0:362–367, 2002.

Referências Bibliográficas X



T. White.

Hadoop: The Definive Guide, chapter 1, 2, 3, pages 1–74. O'Reilly, Sebastopol, CA, USA, 2009.